

Comparação dos modelos MLX para perfis e simulação de atores

Data: 27/09/2026. Máquina: Apple M4 Max, 128 GB. Os três modelos rodaram com o mesmo código de pipeline (utils/), trocando só o backend pelo de mlx_alternative/, na mesma rodada curta com Arnaldo Jardim e Daniela Reinehr. Os números de velocidade e memória vêm de mlx_alternative/runs/benchmark.json.

id	Modelo	Tipo
gemma4_31b	lmstudio-community/gemma-4-31B-it-MLX-8bit	denso, 31B
qwen38_27b	mlx-community/Qwen3.8-27B-8bit	denso, 27B, atenção híbrida
gemma4_26b_a4b	mlx-community/gemma-4-26b-a4b-it-8bit	mistura de especialistas, cerca de 4B ativos

Nenhum dos três atende bem às três partes do pipeline. O Gemma 4 31B escreve os perfis mais fiéis às regras do prompt, mas recusa a múltipla escolha quando recebe o perfil. O Qwen3.8 27B responde a múltipla escolha em todas as condições, mas os perfis dele quebram várias regras do prompt. O Gemma 4 26B-A4B é de 5 a 9 vezes mais rápido que os outros dois, responde com o perfil e recusa na maior parte das vezes quando recebe também os trechos recuperados.

Backend

Nos três modelos, a leitura das letras coincide com o prefill padrão do mlx-lm (diferença de 0,0 nas probabilidades renormalizadas), os 8 passos verificados da geração com guidance coincidem com a combinação calculada por forwards completos, e a geração com $\gamma = 1$ é idêntica à geração sem guidance. O modo de raciocínio ficou desligado nos três, e as letras A a D são um token cada.

Múltipla escolha

A avaliação lê a resposta pelas probabilidades de A, B, C e D no primeiro token. A massa das letras é a soma dessas quatro probabilidades: perto de 1, o modelo está de fato escolhendo uma letra; perto de 0, ele ia começar a resposta por outra coisa, e a letra escolhida sai de probabilidades muito pequenas.

Condição	Gemma 4 31B	Qwen3.8 27B	Gemma 4 26B-A4B
0, sem perfil	0,997	0,996	1,000
1, perfil	0,263	0,993	0,9995
2, perfil e trechos	0,00015	0,985	0,151

Médias nas perguntas de teste da rodada curta. Na validação, a condição 2 teve 0,43 no Gemma 4 26B-A4B e 0,98 no Qwen3.8 27B.

Quando a massa é baixa, a resposta gulosa é uma recusa, como "Nenhuma das alternativas. O material fornecido não contém informações sobre a audiência de 17/04/2024". O system prompt diz que o material da conversa é a única fonte sobre a pessoa, e esse material nunca trata da audiência de teste. Os dois Gemma recusam mais quanto mais material recebem; o Qwen escolhe uma letra nas três condições.

Com 2 perguntas de validação e 3 de teste por modelo, as acurácias da rodada curta não permitem comparar os modelos.

Perfis

Os dois perfis de cada modelo foram lidos contra as regras de `prompts/actor_profile/system_profile.md`. São dois perfis por modelo, de atores com uma audiência de treino cada, então o que segue são exemplos de desvio, sem taxa medida.

	Gemma 4 31B	Qwen3.8 27B	Gemma 4 26B-A4B
Palavras (Arnaldo Jardim / Daniela Reinehr)	316 / 106	530 / 212	381 / 200
Bloco "Forma de argumentar" para Daniela Reinehr, que tem um só turno	omitido	omitido	incluído

Desvios encontrados:

- Gemma 4 31B: "Relaciona seus pleitos a sua base eleitoral", que parece inferência sem apoio nas falas.
- Qwen3.8 27B: sigla expandida ("SAF (Sustainable Aviation Fuel)"), o que o prompt proíbe; especulação entre parênteses ("provavelmente referindo-se à origem paulista"); cortesia registrada como traço ("agradecendo a presença do Ministro"); descrição do que a pessoa não fez ("opta por não aprofundar o tema"); e uma palavra em espanhol ("Pregunta").
- Gemma 4 26B-A4B: traços de "Forma de argumentar" tirados de um único turno ("Adota um tom de acolhimento") ou de uma única frase ("Adota um tom de busca por objetividade"), quando o prompt exige que o traço apareça em mais de um turno.

Geração aberta e guidance

As falas geradas só com o prompt negativo da guidance foram recusas nos três modelos. Com $\gamma > 1$, a guidance afasta a resposta dessa recusa; `ACTOR_SIMULATION.md` já registrava que, nesse caso, ela deixa de corrigir a opinião padrão do modelo.

O γ escolhido na validação foi 1,0 no Gemma 4 31B, 1,5 no Gemma 4 26B-A4B e 3,0 no Qwen3.8 27B, cada um a partir de 2 perguntas. Com $\gamma = 3,0$, a fala do Qwen na abordagem 3 perdeu o sentido: "Presidente quero fazer uma pergunta lige pont Caro Ciocchi do ponto de vista mudanças dias depois ons modific regras despacho [...] security electrical must operate grea". A escolha de γ por acerto, com poucas perguntas, não detecta esse tipo de degradação.

No Qwen3.8 27B e no Gemma 4 26B-A4B, 2 dos 3 pedidos (Arnaldo Jardim na reforma tributária e Daniela Reinehr na BR-101) receberam o nível SEM BASE, e a saída foi a recusa prevista. No Gemma 4 31B, só o da reforma tributária recebeu SEM BASE; o de Daniela Reinehr recebeu

ESPECULATIVA, e a fala leva a acessibilidade, único tema do perfil dela, para uma discussão sobre túneis e contenção de deslizamentos. No pedido de Arnaldo Jardim sobre transição energética em terminais marítimos, os três geraram falas em primeira pessoa que retomam as posições do perfil (segurança do sistema elétrico, biocombustíveis).

Velocidade e memória

	Gemma 4 31B	Qwen3.8 27B	Gemma 4 26B-A4B
Memória após a carga	32,6 GB	28,6 GB	26,8 GB
Pico com o prompt de 66 mil tokens	50,3 GB	42,1 GB	33,9 GB
Prefill do prompt de 66 mil tokens	157 tokens/s (7 min)	207 tokens/s (5,3 min)	1.019 tokens/s (1,1 min)
Geração com prompt curto	13,6 tokens/s	15,9 tokens/s	73,7 tokens/s
Geração com prompt de 66 mil tokens	10,4 tokens/s	13,3 tokens/s	47,8 tokens/s
Segundos por pergunta, validação / teste	76 / 49	77 / 49	12 / 8
Segundos por pedido de simulação	123	90	13

O prompt de 66 mil tokens é o de Erika Kokay, o maior dos 264 perfis de treino.

Tempo projetado da rodada completa

A rodada completa tem 264 perfis (1,72 milhão de tokens de entrada), 81 perguntas de validação, 101 de teste e 53 pedidos de simulação. A projeção usa a velocidade de prefill do prompt longo para toda a entrada, a velocidade de geração do prompt longo para a saída, e os tempos por pergunta e por pedido da rodada curta.

Horas	Gemma 4 31B	Qwen3.8 27B	Gemma 4 26B-A4B
Perfis, com a saída média da rodada curta	5,2	5,3	1,1
Perfis, com 800 tokens de saída por perfil	8,7	6,7	1,7
Avaliação	3,1	3,1	0,5
Simulação	1,8	1,3	0,2
Total	10 a 14	10 a 11	1,8 a 2,4

A saída média da rodada curta foi de 301, 546 e 414 tokens por perfil, para dois atores com pouco material; atores que falam em várias audiências recebem perfis de até 800 palavras, então a linha de 800 tokens está mais perto do esperado. A avaliação e a simulação também devem demorar mais que o projetado, porque perfis maiores deixam os prompts maiores do que os da rodada curta.

Ligar o reuso de prefixo (`backend.prefix_cache`) reduziria o tempo da múltipla escolha por 1,5 a 1,8, mas muda as probabilidades renormalizadas das letras em até 0,05, como registrado no relatório da rodada curta do Gemma 4 31B.

Opções

1. Qwen3.8 27B em tudo. A múltipla escolha funciona como desenhada. Os perfis precisam de leitura, porque trazem siglas expandidas, especulação e cortesia, e a grade de γ precisa perder os valores altos ou ter as falas lidas antes da escolha. Cerca de 10 a 11 h.
2. Perfis com o Gemma 4 31B e múltipla escolha e simulação com o Qwen3.8 27B. Junta os perfis mais fiéis ao prompt com a avaliação que funciona. O pipeline aceita perfis de um modelo e simulação de outro, porque o arquivo de perfis grava o modelo que os gerou, mas o `run.py` usa hoje um único modelo por pasta de rodada e precisaria aceitar os perfis de outra pasta. O artigo precisa registrar os dois modelos. Cerca de 10 a 13 h.
3. Gemma 4 26B-A4B em tudo, com uma mudança no pedido de múltipla escolha (`prompts/actor_simulation/ask_choice.md.j2`) para exigir uma letra mesmo sem certeza. É a única opção que deixa tempo para repetir a rodada, mas a mudança de prompt altera o `prompt_version` e não foi testada; o efeito dela na recusa da condição 2 precisa ser medido antes.

Arquivos

Em `mlx_alternative/runs/`: `benchmark.json` e `benchmark.md` (velocidade, memória e projeções) e, para cada modelo, `<id>/smoke.json`, `<id>/verify.json`, `<id>/actor_profiles/`, `<id>/actor_simulation/` e `<id>/timings.jsonl`. O relatório da rodada curta do Gemma 4 31B está em `gemma4_31b/relatorio_rodada_curta.md`.