

Rodada curta do Gemma 4 31B (8 bits, MLX)

Data: 27/09/2026. Modelo: `lmstudio-community/gemma-4-31B-it-MLX-8bit`, rodado com o backend de `mlx_alternative/` num Apple M4 Max de 128 GB. Atores: Arnaldo Jardim e Daniela Reinehr, os dois indicados em `ACTOR_SIMULATION.md` por terem perguntas em `validation` e em `test`.

O backend MLX funciona e os perfis gerados são bons. A avaliação por múltipla escolha, com o prompt atual, não serve com este modelo: quando recebe o perfil, o modelo responde "Nenhuma das alternativas" em vez de uma letra, e o acerto das condições 1 a 3 passa a ser ruído. A causa está no texto do prompt e aconteceria também com o backend `transformers`.

Backend

A leitura das letras coincide com o prefill padrão do `mlx-lm`: a diferença nas probabilidades renormalizadas entre as quatro letras foi 0,0 nos 8 prompts verificados. Na geração com guidance ($\gamma = 1,5$), os 8 passos conferidos coincidem com a combinação calculada por forwards completos dos dois prompts, e com $\gamma = 1$ a saída é idêntica à da geração sem guidance.

O reuso de prefixo entre prompts (`backend.prefix_cache`) ficou desligado. Ligado, ele mudou as probabilidades renormalizadas das letras em até 0,05, sem trocar a letra de maior probabilidade em nenhum dos 8 prompts. A diferença vem do cálculo em `bf16` sobre o cache, que não reproduz exatamente o do prompt inteiro de uma vez, e poderia trocar a resposta de perguntas quase empatadas.

Perfis

Os dois perfis seguem o formato pedido: os quatro blocos com título fixo, itens começando por verbo e nenhuma frase sobre o que a pessoa não disse. O de Arnaldo Jardim tem 316 palavras e registra as posições sobre regras de despacho do ONS, renovação de concessões por norma legislativa e mistura de biodiesel, além da coordenação da Frente Parlamentar do Etanol. O de Daniela Reinehr tem 106 palavras e omite o bloco "Forma de argumentar", o que está de acordo com o prompt, porque ela tem um único turno de fala. Um item do perfil de Arnaldo Jardim parece inferência sem apoio nas falas: "Relaciona seus pleitos a sua base eleitoral".

Os dois atores têm só uma audiência de treino, então os perfis são curtos por falta de material. O mesmo vale para 79 dos 264 atores da rodada completa.

Múltipla escolha

Para uma pergunta de teste (audiência de 17/04/2024, regulamentação da reforma tributária), o prompt foi remontado nas três condições e o primeiro token gerado foi inspecionado:

Condição	Resposta gulosa	Massa das letras, média no teste
0, sem perfil	A	0,997

Condição	Resposta gulosa	Massa das letras, média no teste
1, perfil	"Nenhuma das alternativas. O material fornecido não contém informações sobre a audiência de 17/04/2024 ou sobre a regulamentação da reforma tributária."	0,26
2, perfil e trechos	"Nenhuma das alternativas."	0,00015

A massa das letras é a soma das probabilidades de A, B, C e D no primeiro token. O system prompt diz que o material da conversa é a única fonte sobre a pessoa; como esse material não trata da audiência de teste, o modelo recusa escolher, e recusa mais quanto mais material recebe. A leitura por letra sempre escolhe entre A e D, então, nas condições 1 a 3, a letra escolhida sai de probabilidades da ordem de 0,01%.

A amostra também é pequena demais para qualquer conclusão sobre acerto: 2 perguntas de validação e 3 de teste, com outras 2 descartadas por falta de distratores. Os três valores de k empataram, e k = 3 foi escolhido por ser o primeiro da grade.

Guidance e geração aberta

As falas geradas só com o prompt negativo da guidance (`negative_speech`) foram todas recusas, como "Como não foi fornecido material com falas anteriores de Arnaldo Jardim, não possuo a base de dados necessária para simular seu posicionamento". Nesse caso, com $\gamma > 1$, a guidance afasta a resposta da recusa. O objetivo dela era afastar a resposta da opinião padrão do modelo, o que exige um prompt negativo que produza uma fala genérica; `ACTOR_SIMULATION.md` já previa essa situação. Na seleção, $\gamma = 1,0$ teve o maior acerto, e as abordagens 2 e 3 produziram falas idênticas.

As falas simuladas são plausíveis e em primeira pessoa, e a conferência da justificativa marcou de 0 a 1 frase sem fundamento por fala. Para Arnaldo Jardim na reforma tributária, o nível de evidência foi SEM BASE e a saída foi a recusa prevista. Para Daniela Reinehr, no estudo da ANTT sobre a BR-101, o nível foi ESPECULATIVA e a fala leva a acessibilidade, único tema do perfil dela, para dentro de uma discussão sobre túneis e contenção de deslizamentos.

Tempo

Etapa	Rodada curta	Rodada completa	Estimativa
Perfis	22 e 48 s por perfil (2,2 mil e 2,7 mil tokens de entrada); geração em torno de 13 tokens/s	264 atores, 1,72 milhão de tokens de entrada (mediana de 4,6 mil, máximo de 66 mil)	7 a 9 h
Avaliação	76 s por pergunta de validação, 49 s por pergunta de teste	81 perguntas de validação e 101 de teste	3 a 4 h
Simulação	cerca de 120 s por pedido	53 pedidos	2 h
Total			12 a 16 h

A estimativa usa as velocidades medidas em prompts de 2 a 3 mil tokens. Os perfis de quem fala muito têm prompts de até 66 mil tokens e devem ser mais lentos que a média.

Uso

O backend e a geração de perfis podem ser usados como estão. A avaliação por múltipla escolha precisa de uma de duas mudanças antes da rodada completa:

1. Mudar o pedido em `prompts/actor_simulation/ask_choice.md.j2` para exigir uma letra mesmo sem certeza. Isso altera o `prompt_version` gravado nas saídas e precisa constar no artigo.
2. Usar um modelo que não recuse. O Qwen3.8 27B e o Gemma 4 26B-A4B estão sendo baixados, e a comparação entre os três deve olhar primeiro o `letter_mass` das condições 1 e 2, depois o tempo.

Se os três modelos recusarem da mesma forma, a mudança 1 é necessária.

Arquivos

Em `mlx_alternative/runs/gemma4_31b/`: `smoke.json`, `verify.json` e `verify_prefix_cache.json` (checagens do backend), `actor_profiles/actor_profiles_train.jsonl` (perfis), `actor_simulation/evaluation.json` e `choice_*.jsonl` (múltipla escolha), `actor_simulation/simulations.jsonl` e `simulations_summary.json` (geração aberta) e `timings.jsonl` (tempos por etapa).