

Rodada completa do Qwen3.8 27B (8 bits, MLX)

Data: 27 e 28/09/2026. Modelo: `mlx-community/Qwen3.8-27B-8bit`, com o backend de `mlx_alternative/` num Apple M4 Max de 128 GB. Código em `6025c77`, com o prompt de múltipla escolha e o system prompt de simulação revisados nesse commit (`prompt_version` `4a5995d1da8a` da simulação e `a80b3a121fab` dos perfis). Perfis gerados só com as audiências de `train` do split `temporal_v1`; `k` e `γ` escolhidos em `validation`; resultados em `test`.

No teste, o perfil aumentou o acerto da múltipla escolha de 30,7% para 42,6%, uma diferença de 11,9 pontos percentuais com intervalo de 95% de [4,9; 19,6]. Os trechos recuperados acrescentaram 2,0 pontos, com intervalo que inclui zero, e a guidance não entrou, porque $\gamma = 1,0$ teve o maior acerto na validação. Os níveis de evidência não ordenaram o acerto como o desenho exige.

Execução

Etapa	Volume	Duração
Perfis	264 atores, nenhuma falha; 1,70 milhão de tokens de entrada e 239 mil de saída	6,2 h
Múltipla escolha, validação	81 perguntas de 51 atores em 21 audiências	2,8 h
Múltipla escolha, teste	101 perguntas de 46 atores em 24 audiências	2,0 h
Geração aberta	53 pedidos	2,1 h

Das UDV's ligadas a atores com perfil, 21 de 102 em validação e 5 de 106 em teste foram descartadas por não terem 3 outros atores na mesma audiência para servir de distratores. A avaliação e a geração aberta demoraram mais que a projeção feita com a rodada curta, porque os perfis da rodada completa são maiores (mediana de 610 palavras) e deixam os prompts mais longos.

Múltipla escolha

Cada pergunta mostra 4 proposições da mesma audiência, uma do ator, e o acaso é 25%. A resposta é lida pelas probabilidades das letras no primeiro token, com média das 4 rotações da ordem das opções.

Condição	Acerto, teste	Probabilidade média da opção certa, teste	Acerto, validação
0, nome e cargo	30,7%	0,295	35,8%
1, perfil	42,6%	0,366	45,7%
2, perfil e trechos (k = 3)	44,6%	0,402	49,4%
3, condição 2 com guidance ($\gamma = 1,0$)	44,6%	0,402	49,4%

Diferença no teste	Acerto	Intervalo de 95%
1 menos 0	+11,9 pontos	[+4,9; +19,6]
2 menos 1	+2,0 pontos	[-2,9; +7,0]
3 menos 2	0	[0; 0]

Os intervalos vêm de bootstrap pareado com 1.000 reamostragens de audiências inteiras, porque as perguntas de uma audiência compartilham assunto e participantes.

Na validação, o acerto da condição 2 foi de 49,4%, 48,1% e 46,9% com $k = 3, 5$ e 10 , e o da condição 3 foi de 49,4%, 48,1%, 46,9% e 43,2% com $\gamma = 1,0, 1,5, 2,0$ e $3,0$. O acerto caiu à medida que k e γ subiram, e os dois ficaram no primeiro valor da grade.

A massa das letras (soma das probabilidades de A, B, C e D no primeiro token) ficou entre 0,998 e 0,999 em média nas condições 0 a 2, com mínimo de 0,969 no teste. Com o prompt anterior ao 6025c77, o piloto de dois atores tinha dado entre 0,985 e 0,996 para este modelo; nos dois modelos Gemma do piloto, a massa caía para até 0,00015 com o prompt anterior, e o efeito da revisão neles não foi medido.

Níveis de evidência

O desenho em `ACTOR_SIMULATION.md` considera que os níveis se sustentam se o acerto cair de DIRETA para ESPECULATIVA. No teste:

Nível	Condição 1: perguntas / acerto	Condição 2: perguntas / acerto
DIRETA	22 / 54,5%	22 / 54,5%
INDIRETA	30 / 36,7%	38 / 36,8%
ESPECULATIVA	15 / 46,7%	19 / 52,6%
SEM BASE	34 / 38,2%	22 / 40,9%

DIRETA teve o maior acerto, mas ESPECULATIVA ficou acima de INDIRETA nas duas condições. Não foi calculado intervalo para as diferenças entre níveis; com 15 a 38 perguntas por nível, elas não permitem afirmar uma ordem, e os níveis não podem ser apresentados como calibração da confiança.

Geração aberta

	Abordagem 1, perfil	Abordagem 2, perfil e trechos
Falas geradas	38	40
Recusas (nível SEM BASE)	15	13
Níveis DIRETA / INDIRETA / ESPECULATIVA	8 / 23 / 7	9 / 25 / 6
Frases sem fundamento na conferência	27 de 415 (6,5%)	34 de 441 (7,7%)
Falas ou justificativas truncadas	0	0

	Abordagem 1, perfil	Abordagem 2, perfil e trechos
Trechos de justificativa que não puderam ser lidos como JSON	2	0

A conferência verifica que cada frase cita um item existente no material e que a cópia citada é literal; ela não verifica se o item sustenta a frase, o que exige leitura humana.

A fala gerada só com o material da condição 0 (`baseline_speech`) começa com uma recusa em 38 dos 53 pedidos. A contagem é aproximada: ela procura expressões como "não há material" e "não possuo" no texto, sem leitura das falas.

Limitações

- O prompt da múltipla escolha e o system prompt foram revisados depois do piloto de 27/09, que usou perguntas de audiências de `test`. A revisão se baseou na massa das letras e na leitura das respostas, sem uso do acerto, como registrado em `ACTOR_SIMULATION.md`, e o artigo precisa declarar essa sequência.
- 28 dos 264 perfis passam do teto de 800 palavras do prompt de perfil; o maior tem 1.209. No piloto, os perfis deste modelo também traziam siglas expandidas, especulação entre parênteses e cortesia registrada como traço, o que o prompt proíbe. A frequência desses desvios nos 264 perfis não foi medida.
- Os resultados são de um único modelo, quantizado em 8 bits, e de uma única semente.
- O teste tem 101 perguntas em 24 audiências. O intervalo do efeito do perfil vai de 4,9 a 19,6 pontos.

Arquivos

Em `mlx_alternative/runs/qwen38_27b/`: `actor_profiles/actor_profiles_train.jsonl` (264 perfis), `actor_simulation/evaluation.json`, `choice_validation.jsonl` e `choice_test.jsonl` (múltipla escolha), `actor_simulation/simulations.jsonl` e `simulations_summary.json` (geração aberta), `timings.jsonl` (tempos) e `full_run.log`. As saídas do piloto com o prompt anterior estão em `archive_prompts_109a670/`.